

# [15강]

## 사전분포와 베이지 검정

서울대학교 통계학과 이재용 교수

# 학습목표

1. 사전분포

---

2. 정규모형

---

3. 베이지스 가설 검정

---

# [ 15강 ]

사전분포와 베이지스 검정



## 사전분포

## 1.1

## 컬레사전분포

- 어떤 통계모형의 사후분포가 사전분포의 집합에 포함될 때, 사전분포의 집합을 그 통계모형의 컬레사전분포의 집합이라 하고, 그 원소를 컬레사전분포라 한다.

## 1.1

## 켈레사전분포

- $X|\theta \sim B(n, \theta)$ 이고,  $\theta \sim \text{Beta}(\alpha, \beta)$ 이면,  
 $\theta|X = x \sim \text{Beta}(\alpha + x, \beta + n - x)$ 이다.  
 사전분포와 사후분포 모두 베타분포이므로,  
 베타분포는 이항모형의 켈레사전분포이다.
- $X_1, X_2, \dots, X_n | \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2), \sigma^2 > 0$ 는 알려진 값이라 하자.  
 $\theta \sim N(\mu, \tau^2)$ 이면

$$\theta|X_1, \dots, X_n \sim N\left(\frac{\frac{1}{\tau^2}\mu + \frac{n}{\sigma^2}\bar{x}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}, \left(\frac{1}{\tau^2} + \frac{n}{\sigma^2}\right)^{-1}\right) \text{이다.}$$

따라서 정규분포는 정규모형의 켈레사전분포이다.

## 1.2 이항모형에서 베타사전분포 모수의 결정

- $X|\theta \sim B(n, \theta)$ 이고,  $\theta \sim \text{Beta}(\alpha, \beta)$ 이면,
- $\theta|X = x \sim \text{Beta}(\alpha + x, \beta + n - x)$ 이다.

이 때, 사후평균은 다음과 같다.

$$\hat{\theta}^B = \frac{\alpha + x}{\alpha + \beta + n} = \frac{\alpha + \beta}{\alpha + \beta + n} \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \frac{x}{n}$$

- 베이즈 추정량은 사전분포의 평균과 자료로 이루어진 최대가능도추정량의 가중평균이고, 가중치는 각각  $\alpha + \beta$  와  $n$ 이다.
- $\alpha + \beta$  를 사전자료의 크기라 하고 사전분포가 가지고 있는 정보의 양으로 해석한다.

## 1.2

## 이항모형에서 베타사전분포 모수의 결정

- 이항 - 베타모형에서 자료를 보기 전에  $\theta$ 의 그럴듯한 값이  $\theta_0$ 이고, 이 정보는 관측치  $k$ 개가 갖고 있는 정보량 만큼 확신을 갖고 있다면

$$\frac{\alpha}{\alpha + \beta} = \theta_0, \alpha + \beta = k \text{ 라 놓고,}$$

이를 풀면  $\alpha = \theta_0 k, \beta = (1 - \theta_0)k$  를 얻는다.

## 1.2 이항모형에서 베타사전분포 모수의 결정

예 이항모형

- $X|\theta \sim B(n, \theta)$ 이고,  $\theta \sim \text{Beta}(\alpha, \beta)$ 인 이항 - 베타모형을 고려하기로 하였다.  
자료를 보기 전에  $\theta$ 는  $1/4$  근처일 것이라 예상되고  
이는 약 **0.1**개의 관측치 만큼 확신이 든다고 할 때  
사전분포의 모수  $\alpha, \beta$ 를 구하라.



## 1.3

## 정규모형에서 정규사전분포 모수의 결정

- $X_1, X_2, \dots, X_n | \theta \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2), \sigma^2 > 0$ 는 알려진 값이라 하자.  
 $\theta \sim N(\mu, \tau^2)$ 이라 하자. 이때, 사후평균은 다음과 같다.

$$\hat{\theta}^B = \frac{\frac{1}{\tau^2} \mu + \frac{n}{\sigma^2} \bar{X}}{\frac{1}{\tau^2} + \frac{n}{\sigma^2}}$$

- 베이즈 추정량은 사전분포의 평균과 최대가능도추정량의 가중평균이고, 가중치는 각각  $1/\tau^2$  와  $n/\sigma^2$  이다.
- 분산의 역수는 정밀도라 불리고 정규분포가 가지고 있는 정보의 크기로 해석한다.

## 1.3

## 정규모형에서 정규사전분포 모수의 결정

- 정규 – 정규모형에서 자료를 보기 전에  $\theta$ 의 그럴듯한 값이  $\theta_0$ 이고,  
이 정보는 관측치  $k$ 개가 갖고 있는 정보량 만큼  
확신을 갖고 있다면  $\theta$ 의 사전분포는  
$$\theta \sim N(\theta_0, \sigma^2/k)$$
가 된다.

## 1.3

## 정규모형에서 정규사전분포 모수의 결정

예 정규모형

- $X_1, X_2, \dots, X_n | \theta \stackrel{i.i.d.}{\sim} N(\theta, 4)$ 를 따르는 확률표본이고  $\theta$ 의 사전분포를 구하라.  
 $\theta$ 의 사전분포는 정규분포를 쓰기로 하였다.  
자료를 보기 전에  $\theta$ 는 10 정도로 예상되고  
이는 관측치 0.5개 만큼의 확신이 든다.  
 $\theta$ 의 사전분포를 구하라.

## 1.4

## 무정보사전분포

- 주관적 사전분포를 이용하는 것이 이상적이지만 실제 분석에 사용할 때는 어려움이 따른다. 자신의 의견을 정확하게 확률분포로 나타내는 것은 많은 시간과 노력이 필요하다.
- 분석결과를 공유할 때는 모든 사람들이 수용할 수 있는 사전분포가 유용하다.
- 주관적 정보를 전혀 포함하지 않는 사전분포를 무정보사전분포라 한다.
- $\pi(\theta) = 1, \forall \theta$ 를 균일사전분포라 한다.
- 많이 쓰는 무정보사전분포에는 균등사전분포와 제프리스의 사전분포가 있다.

# [ 15강 ]

사전분포와 베이지 검정



## 정규모형

## 2.1 정규모형과 사전분포

- $X_1, X_2, \dots, X_n \stackrel{i.i.d.}{\sim} N(\theta, \sigma^2)$ 을 따를 때,  $\theta$ 와  $\sigma^2$  모두 추론하고자 한다.
- $\theta$ 와  $\sigma^2$ 의 사전분포로 다음의 분포를 고려한다.

$$\theta | \sigma^2 \sim N(\mu_0, \frac{\sigma^2}{K_0})$$

$$\sigma^2 \sim \text{Inv-Gamma}(\frac{\nu_0}{2}, \frac{\nu_0}{2} \sigma_0^2)$$

$\mu_0$ 는 자료를 관측하기 전  $\theta$ 의 예측값,  $K_0$ 는  $\theta$ 의 정보에 대한 사전정보의 크기,  $\sigma_0^2$ 은 자료를 관측하기 전  $\sigma^2$ 의 예상값이다.

- $X \sim \text{Gamma}(\alpha, \beta)$ 일 때,  $1/X$ 의 분포를 역감마분포라 하고,  $\text{Inv-Gamma}(\alpha, \beta)$ 라 표시한다.

## 2.2 사후분포

$$\theta | \sigma^2 \sim N(\mu_n, \frac{\sigma^2}{k_n})$$

$$\sigma^2 \sim \text{Inv-Gamma} \left( \frac{v_n}{2}, \frac{v_n}{2} \sigma_n^2 \right)$$

사후분포의 모수들은 다음과 같이 정의된다.

$$\mu_n = \frac{k_0 \mu_0 + n \bar{x}}{k_0 + n}$$

$$k_n = k_0 + n$$

$$v_n = v_0 + n$$

$$\sigma_n^2 = \frac{1}{v_n} \left[ v_0 \sigma_0^2 + (n-1) s^2 + \frac{k_0 n}{k_n} (\bar{x} - \mu_0)^2 \right]$$

여기서  $s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$  이다.

## 2.3 $\theta$ 의 추정

- $\theta$ 의 주변사후분포는

$$\theta | X_1, \dots, X_n \sim t_{v_n}(\mu_n, \frac{\sigma^2}{K_n}) \text{ 이다.}$$

여기서  $t_{v_n}(\mu, \sigma^2) = \bar{\mu} + \sigma t_{v_n}$ 을 의미한다.

- $\theta^B = \mu_n$
- $\theta$ 의  $100(1 - \alpha)\%$  신용구간은

$$\mu_n + t_{\alpha/2}(v_n) \frac{\sigma_n}{\sqrt{K_n}} \text{ 이다.}$$

무정보사전분포를 쓰면, 신용구간은 빈도론자들의 신뢰구간과 동일하게 된다.



# [ 15강 ]

사전분포와 베이지스 검정



## 3 베이지스 가설 검정

## 3.1

## 베이즈 가설검정

- 모형

$$x | \theta \sim f(x | \theta), \theta \in \Theta$$

- 가설

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta = \theta_1$$

- 혹은

$$H_0 : x \sim f(x | \theta_0) \text{ vs } H_1 : x \sim f(x | \theta_1)$$

## 3.2 가설검정의 사전분포

- $\pi_0 = \pi(H_0)\pi_1 = \pi(H_1)$   
여기서  $\pi_0 + \pi_1 = 1, 0 < \pi_0, \pi_1 < 1$ 이다
- 자료를 보기 전에  $H_0$ 와  $H_1$ 가 동일한 가능성을 갖는다고 생각되면 다음과 같이 놓는다.

$$\pi_0 = \pi_1 = \frac{1}{2}$$

## 3.3

## 사후확률

$$\pi(H_0|x) = \frac{\pi_0 f(x|H_0)}{\pi_0 f(x|H_0) + \pi_1 f(x|H_1)}$$

여기서  $f(x|H_0) = f(x|\theta_0)$ 이고  $f(x|H_1) = f(x|\theta_1)$ 이다.

## 3.4 베이지스 인수(Bayes Factor)

- 사후확률의 비(Posterior odds)

$$\frac{\pi(H_1|x)}{\pi(H_0|x)} = \frac{\pi_1 f(x|H_1)}{\pi_0 f(x|H_0)}$$

혹은,

$$\text{사후확률의 비} = \frac{f(x|H_1)}{f(x|H_0)} \times \text{사전확률의 비}$$

- 베이지스 인수(베이지스 인자, 베이지스 팩터)

$$B_{10} = \frac{\pi_1 f(x|H_1)}{\pi_0 f(x|H_0)}, B_{01} = \frac{1}{B_{10}}$$

- 사후확률의 비 = 베이지스 인수  $\times$  사전확률의 비
- 사전확률의 비가 1일때 즉,  $\pi_0 = \pi_1 = 1/2$ 일때,  
베이지스 인수는 사후확률의 비와 같다.

## 3.4 베이지스 인수(Bayes Factor)

### 압정의 예

- 모형  $x | \theta \sim \text{Bin}(n = 10, \theta)$
- $x = 7$ 을 관측했다고 하자.
- 다음의 가설 검정을 고려해보자.

$$H_0 : \theta = 1/2 \text{ vs } H_1 : \theta = 2/3$$

- 사전확률

$$\pi_0 = \pi_1 = 1/2$$

## 3.4 베이지스 인수(Bayes Factor)

- 베이지스 인수

$$\begin{aligned} B_{10} &= \frac{f(x = 7 | \theta = 2/3)}{f(x = 7 | \theta = 1/2)} \\ &= \frac{\binom{10}{7} (2/3)^7 (1/3)^3}{\binom{10}{7} (1/2)^7 (1/2)^3} \\ &= 2.2197 \end{aligned}$$

- 가설들의 사후확률

$$\begin{aligned} \pi(H_1 | x) &= \frac{\pi_1 B_{10}}{\pi_1 B_{10} + \pi_0} = 0.6894 \\ \pi(H_0 | x) &= 1 - \pi(H_1 | x) = 0.3106 \end{aligned}$$

## 3.5

## 베이지 팩터의 값에 대한 제프리스(Jeffreys)의 기준

$\log_{10} B_{10}$	$B_{10}$	$H_1$ 에 대한 증거의 정도
$0 - \frac{1}{2}$	$1 - 3.2$	언급할 만한 가치가 없는 증거 ( <i>not worth a bare mention</i> )
$\frac{1}{2} - 1$	$3.2 - 10$	상당한 증거( <i>substantial</i> )
$1 - 2$	$10 - 100$	강한 증거( <i>strong</i> )
$> 2$	$> 100$	결정적 증거( <i>decisive</i> )



한 학기 동안

수고하셨습니다.

감사합니다.